技术贡献及定位

冻结代码：99660b36db9d5b1121eea6fe06b026c5f1e36bcf

可验证的工具准入、蜜罐信号与目标效果证据整合。授权、检测、拒绝、真实副作用必须分别评价。

成熟能力控制/日志/蜜罐思想已有先行工作，本项目的贡献是可运行组合与可核查闭环，不是分层命名或首创宣称。

候选贡献一：执行前控制

绑定文件资源句柄、宿主登记固定程序/argv、明确MCP capability；实际目标与合法正对照共同证明限定拒绝效果。

同Guard对象共享队列和敏感latch防止旧TTL/双网关竞态；保护范围是单JS进程内注册调用。

未具备完整任务grant、父委托撤销、OS隔离及任意不合作回调取消。

候选贡献二：可审查证据

OSEP0.1定义请求、决策、执行状态、效果验证及链摘要。标准Schema与运行时一致性、缺证据降级负例形成可复验检查。

新P2验收器缺证据仍保留E3已修复：无效元数据、正对照、源/构建、链或效果记录整体失败并降级；不是产品自动认证系统。

E3同host观察与E4独立再现严格区分；没有外部锚、签名或时间戳，不宣传绝对防篡改。

候选贡献三：诱饵隔离与研究限制

唯一ID的隔离虚拟资源、真实交互事件、Guard隔离与后续调用拒绝。可信任务选择机制可测试。

尚未验证自适应比静态更有效，也未测AI的独立净阻断贡献。保留正常中断、未尝试攻击及失败案例。

轻量来源关联不等于完整污点或因果推断；受控SDK结果不代表原生Codex/Claude/Cursor保护。

相关工作与可复现差异

Canarytokens MCP：https://docs.canarytokens.org/guide/mcp-token

CaMeL：https://arxiv.org/abs/2503.18813

AgentDojo：https://arxiv.org/abs/2406.13352

Promptfoo：https://www.promptfoo.dev/docs/red-team/；PyRIT：https://github.com/Azure/PyRIT

以上是机制/研究定位比较，没有安装或统一测量对方性能。作品可与评测框架互补，不能由不同样本结果排名。