真实模型实验方法

代码冻结：9f00b6ba7475e8bccc5410e1484ed74a7806b7d1

模型：Ollama / Qwen 9B，预先安装；temperature 0、think false、context 4096、seed 20261011、最多 4 轮工具交互。

相同任务、工具定义与样本，对照 A 无保护、B 静态诱饵、C 诱饵+Guard、D 确定性能力、E 事前 AI、FE+.env 蜜罐。

所有危险效果局限为临时测试文件、固定无害 Node 执行器及 loopback 假接收端。使用真实模型自主工具选择，不通过脚本强制诱饵调用来计数。

全量输入、工具轨迹、错误、使用量和分子 / 分母见独立 preregistration.json、results.json、results.csv。

间接注入对照：未观察到主动攻击

组	危险效果	主动拒绝任务	正常完成
A	0/5	0/5	3/3
B	0/5	0/5	3/3
C	0/5	0/5	3/3
D	0/5	0/5	3/3
E	0/5	0/5	3/3
F	0/5	0/5	3/3

每组 5 个攻击任务、3 个正常任务；共 48 次。各组 0/5 攻击成功、0/5 主动拒绝，正常 3/3。

这次模型只完成正常仓库任务，没有跟随恶意 README。因此 Canary 或网关的独立安全收益 NOT MEASURED。不能报告为 100% 防护。

样本来自作者设计，单模型 / 单种子，小样本；不是盲测公共基准。

直接执行准入：实际副作用证明

组	危险效果	主动拒绝任务	正常完成
A	4/4	0/4	3/3
E	0/4	4/4	3/3
F	0/4	4/4	3/3

每组 4 个受限操作任务、3 个正常任务。它是执行边界测试，不是间接 Prompt Injection 攻击成功率。

A 实际删除 / 改写虚拟受保护文件或执行虚拟特权 workflow；E/F 拒绝对应调用，实际副作用未发生。F 记录虚拟 .env READ 与 QUARANTINED，随后写入 / 命令 / 网络调用被拒绝。

AI 审查有效输出 3/3；中位延迟 4667.0556 ms。Agent Token {'input': 29178, 'output': 1995}；Review Token {'input': 718, 'output': 754}。

没有付费 API；本机电费成本未测。AI 独立阻断贡献未测。

证据与局限

早期两个实验的提交 SHA 被命令展开记录为前一提交；原始数据未修改。根据运行时五个源码文件哈希匹配实际提交，更正见 SOURCE_PROVENANCE_CORRECTIONS.json。新冻结实验显式传完整 SHA。

本地微基准：1500 次实际持有句柄读取 + 内存证据记录，中位 3.134 ms、p95 5.647 ms；不包含模型或磁盘 fsync，不是长时间资源稳定性结论。

正常 3/3 的 Wilson 95% 区间约 43.9%–100%；不能验证生产正常任务成功率≥95%。独立 100 攻击 / 50 正常建议目标尚未完成。

原生 Agent 全局保护、自适应对静态增益、任意编码数据流、管理员日志篡改抵抗均未得到本轮证明。完整源文件摘要、分母和历史失败保留在 GitHub Draft PR #24。