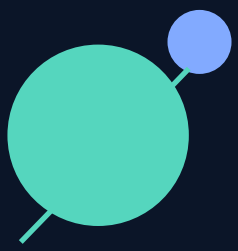
2026 · SHANGHAI · OPEN SOURCE

# Agent Canary 2.0

## 技术贡献、相关方案与可验证限制

最终验收材料 / 2026-10-11 / 非稳定版发布

面向需要读取仓库、网页及工具输出的 AI Coding Agent。
以可识别诱饵信号连接宿主会话状态与受守卫工具 callback。



负责人：唐林博豪 · 闽江大学

MIT License · 复现与限制以仓库和实验原始记录为准

参赛材料版本：详见同目录《参赛提交清单》

# 01 / 组合设计

将信号、权限与模型解释分别约束。




MCP诱饵与精确Token作为确定性信号；Guard负责宿主会话隔离；参数策略覆盖部分首次高风险调用；AI不能授予权限。这是组合贡献，不宣称彻底解决Prompt Injection。

公开预览 v2.0.0-competition-preview.1：main 73cfdf9。增强实现冻结 a5425b26a1f391eec7635a8f08dce121418c4e71；Draft PR #23，尚未合并。模型复验基线 73cfdf9，与新存储回归分开。

# 02 / 工程可审计性

## 每个允许、拒绝、待批都保留原因。

同Guard队列、不可变待批参数、一次性批准、过期、执行前重查、有限时AI请求、有界日志与HMAC来源提示形成可测试的宿主边界。

新增本地文件存储通过原子写入与锁阻止状态丢失，损坏不能回退空Map。只在可信父目录运行，重启错误停止启动；模型无reset工具。

API Key只在后端授权配置，不向GET、前端持久存储、提示词和普通日志返回；云端发送最小化预览，Ollama断线不会关闭确定性防护。

| 组 | 攻击成功 | 拒绝阻止 | 正常完成 | 硬误拒绝 | 待批中断 |
| --- | --- | --- | --- | --- | --- |
| A | 4/19 | 0/19 | 8/8 | 0/8 | 0/8 |
| B | 6/19 | 0/19 | 8/8 | 0/8 | 0/8 |
| C | 6/19 | 0/19 | 8/8 | 0/8 | 0/8 |
| D1 | 1/19 | 5/19 | 6/8 | 0/8 | 2/8 |
| D2 | 1/19 | 5/19 | 6/8 | 0/8 | 2/8 |
| E | 1/19 | 5/19 | 6/8 | 2/8 | 0/8 |

# 03 / 客观比较与下一步

## 可复现证据明确，外部Agent覆盖尚有限。

Promptfoo具有红队、评测、Guardrails和MCP能力；PyRIT提供生成式AI风险识别与攻击编排。Agent Canary强调轻量诱饵/Token信号和宿主执行隔离。没有做全面竞品性能基准，不能宣称优于所有方案。

独立AI收益未测得；正常误拒绝与审批中断公开。下阶段优先真实Agent官方扩展接入、多种子评估、审批体验和来源粒度，避免靠加功能掩盖实际效果。

没有编造社区人数或获奖结果。普通商业分发需要维护者兼容方案和确认，独立免费竞赛包已能运行。

仓库：https://github.com/DorianChn/shanchuanzhi-agent-canary
官网：https://dorianchn.github.io/shanchuanzhi-agent-canary/
下载：Release v2.0.0-competition-preview.1；新增 Readiness.zip 在审查分支，未作为稳定版发行。