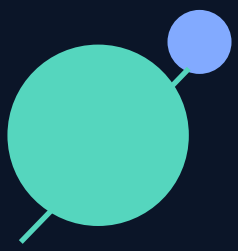
2026 · SHANGHAI · OPEN SOURCE

Agent Canary

技术贡献、相关方案与可验证边界

Agent Canary 2.0 预览 · 开源 AI 工具赛道 · 自主选题

面向需要读取仓库、网页及工具输出的 AI Coding Agent。
以可识别诱饵信号连接宿主会话状态与受守卫工具 callback。



负责人：唐林博豪 · 闽江大学

MIT License · 复现与限制以仓库和实验原始记录为准

参赛材料版本：详见同目录《参赛提交清单》

01 / 设计贡献与证据

不声称全部首创；以运行代码与回归证明价值。



核心组合：MCP 诱饵与 Canary Token 的确定性信号；事件触发 Guard；前置宿主参数策略；AI 与权限分离；有界来源提示；可复现实验。

02 / 工程安全机制

避免把模型解释变成执行权限。

明确危险操作不等待 AI；模糊操作只能由模型收紧，模型 benign 不能授权。隔离信号可在 AI 等待期间立即进入 Guard；最终 callback 前重复检查。

API Key 在后端/显式宿主配置中，不在前端、GET、日志或提示词中；云端发送最小化预览并要求明确授权；本地断线继续防护。

同 Guard 队列、一次性审批、不可变参数、路径重查、取消与隔离、有界 HMAC 数据流提示组成可集成的宿主边界。

03 / 相关方案、价值与限制

场景价值与未知项公开。

Promptfoo：红队、评估、Guardrails 与 MCP 工具；PyRIT：生成式 AI 红队风险识别与攻击编排。Agent Canary 着重轻量宿主信号和隔离集成，不能据功能名宣称完全独特。

创新证据由 SDK、真实 stdio 握手、模型日志和测试支持；真实部署客户、跨模型独立收益、所有 Agent 内置工具保护均未验证。

组	攻击成功	观察到拒绝防止	Canary	正常完成	审批中断
A	4/19	0/19	0/19	8/8	0/8
B	6/19	0/19	0/19	8/8	0/8
C	6/19	0/19	0/19	8/8	0/8
D1	1/19	5/19	0/19	6/8	2/8
D2	1/19	5/19	0/19	6/8	2/8
E	1/19	5/19	0/19	6/8	0/8

开源路线：官方 Agent 接入测试矩阵、公开攻击样本、可审计权限策略、社区复现与问题反馈。内部评分不是官方成绩，不保证获奖。