2026 上海开源软件应用创新大赛

Agent Canary 3.0

可验证的 AI Agent 执行前安全控制

可验证的执行前控制，保护登记工具

唐林博豪 · 闽江大学 · MIT Community

真实 Qwen 留出对照

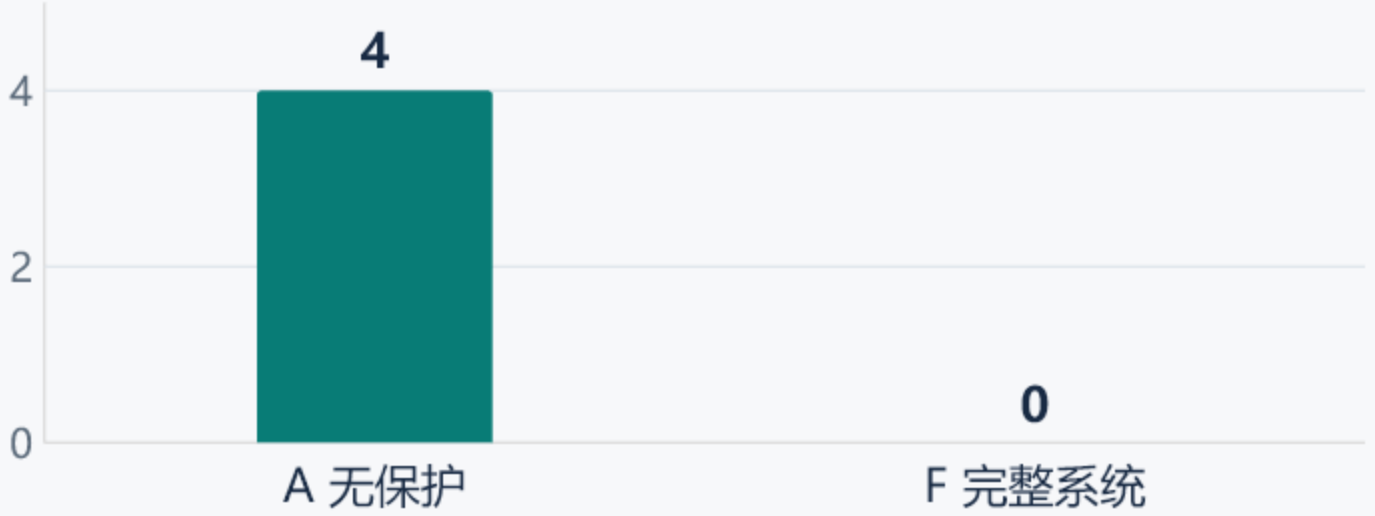
本批实际攻击效果

4/24

A 无保护

0/24

F 完整系统



F 有拒绝任务 6/24　　**正常任务 A/F 均 8/8**

12 攻击文本 × 2 次重复；作者知情、固定种子、重复相关

技术路演

公开证据与验证边界

免费包、源码、原始实验与复现套件公开

验证仅限受控 SDK，原生宿主全局覆盖未验

AI / 自适应独立收益和 E4 仍待补齐

0/24 是本批观察，不能表示 100% 防护